北京化工大学

第二十一届“萌芽杯”参赛作品—B 类

作品名称：基于 VLA 的小型机械臂验证及智能服务场景应用研究

指导教师： 李好义

负 责 人： 崔道涵

联系方式： 19560829506

2026 年 9 月 19 日

团队成员及指导老师介绍

指导老师介绍：

姓　　名	李好义	所属学院	机电工程学院
职　　称	副教授	研究方向	超细纤维先进制造工艺及装备

团队成员介绍：

姓　　名	崔道涵	所属学院	机电工程学院
专　　业	机器人工程	班　　级	机工 2502

姓　　名	李择成	所属学院	机电工程学院
专　　业	过程装备与控制工程	班　　级	装备

姓　　名		所属学院	
专　　业		班　　级	

姓　　名		所属学院	
专　　业		班　　级	

姓　　名		所属学院	
专　　业		班　　级	

目　录

第 1 章 项目概述与研究背景 4
第 1.1 节 项目简介 4
第 1.2 节 项目背景与研究意义 4
第 1.3 节 国内外研究现状 5
第 2 章 系统设计与实施方法 6
第 2.1 节 平台组成与软件架构 6
第 2.2 节 任务设置与示教采集 6
第 2.3 节 数据处理与模型微调 7
第 2.4 节 推理部署与评估方法 7
第 3 章 已完成工作与阶段结果 8
第 3.1 节 平台搭建与采集流程 8
第 3.2 节 数据规模与质量检查 8
第 3.3 节 模型训练与验证结果 9
第 4 章 待解决问题与进度安排 10
第 4.1 节 待解决的关键问题 10
第 4.2 节 后续进度计划 10
第 4.3 节 预期成果与应用边界 11
第 5 章 总结 11
参考文献 11

第 1 章 项目概述与研究背景

第 1.1 节 项目简介

本项目以低成本 SO-ARM101 主从机械臂为实验平台，配置外部视角与腕部视角两路 RGB 摄像头，基于 LeRobot 开源框架和 SmolVLA 预训练模型，开展面向桌面物体抓取与放置的模型适配和应用验证。项目采用“遥操作示教—数据处理—模型微调—推理部署—实机评估”的技术路线，拟形成可复现的实验平台、数据处理流程和任务评估方案。

项目第一阶段围绕“拿起黄色方块并放入网状容器”开展基础能力验证；第二阶段拟在基础任务稳定后拓展至物品归位、分类放置等桌面服务场景。目前已完成平台搭建、主从遥操作、双视角数据采集和首轮模型微调，尚未完成本轮模型的实机推理及自主抓取成功率评估。

第 1.2 节 项目背景与研究意义

传统机械臂在结构化环境中能够稳定完成重复作业，但物体位置、外观和任务要求发生变化时，往往需要重新编程或调整感知与控制规则。桌面整理、物品归位等场景具有物体摆放不固定、操作目标多样等特点，因此有必要研究结合环境观察和任务指令生成动作的机器人控制方式。

视觉—语言—动作（Vision-Language-Action，VLA）模型将视觉信息、语言条件与动作学习结合，为机器人利用预训练知识和示教数据适配具体操作任务提供了路径。对于学生科研项目，研究重点不仅是完成模型训练，更是建立能够追溯数据、核对模型输入输出并进行重复实机测试的完整实验流程。

本项目的实践价值在于：利用低成本机械臂建立具身智能实验平台；分析示教数据和视觉配置对任务适配的影响；通过桌面服务任务检验系统的适用范围与稳定性。项目以开源模型的场景适配、系统集成和实验评估为主要内容，不将使用现有模型本身作为原创算法成果。

第 1.3 节 国内外研究现状

国外研究正由单任务策略学习逐步发展为结合视觉语言预训练知识与机器人示教数据的策略研究。RT-2 将视觉语言模型与机器人动作学习结合，探索把网络数据中的语义知识迁移到机器人控制任务中，为 VLA 研究提供了代表性路线[1]。OpenVLA 开放模型及训练代码，研究利用多样化示教数据进行预训练并适配新的操作任务，为开源条件下的实验提供了基础[2]。

针对较大模型训练与部署成本较高的问题，SmolVLA 提出较小规模的视觉—语言—动作模型，并研究异步推理方式，以改善感知、动作预测和动作执行的协同效率[3]。国内方面，上海人工智能实验室的 InternVLA-M1 将空间理解与动作生成结合，通过空间引导的训练方式，研究语言指令、目标位置与机器人操作之间的关联，并在抓取放置等任务中开展验证[4]。

现有工作为 VLA 在机器人平台上的应用提供了基础，但公开实验结果不能直接等同于本项目设备上的效果。模型迁移到新的机械臂、摄像头安装位置与桌面环境后，仍需核对数据质量、动作表示、推理延迟和通信稳定性。本项目选择轻量化开源模型，重点研究其在具体低成本平台上的适配与验证。

在方法选择上，RT-2、OpenVLA 和 SmolVLA 均为视觉与动作学习提供了参考，但它们所用数据规模、模型参数和硬件条件不同，不能直接比较论文中的指标并据此推断本项目的抓取效果。本项目优先选用已有 LeRobot 训练流程支持的 SmolVLA，以减小系统适配范围，把精力集中在相机输入、关节动作与实机执行是否一致的验证上。

本项目的研究问题可以进一步归纳为三项：双视角图像能否为同一操作任务提供稳定观察；有限示教数据是否足以使预训练策略适应当前机械臂和桌面；离线验证结果与实机操作成功率是否一致。针对这些问题，将在固定机位任务上先建立基线，再逐步改变视角和物体起始位置，避免同时改变多个条件而无法解释结果。

第 2 章 系统设计与实施方法

第 2.1 节 平台组成与软件架构

系统由主从机械臂、双 RGB 摄像头、本地采集与控制计算机以及开发机训练环境组成。LeRobot 提供数据处理、训练及部署工具[5]。SO-ARM101 开源机械结构用于本项目的示教与执行平台[6]，LeLab 用于辅助设备配置和采集操作[7]。本项目的动作与状态均为六维，对应五个机械臂关节及一个夹爪通道，不将其表述为工业机械臂完整六自由度末端位姿控制。

主臂用于遥操作示教，从臂执行对应动作。外部相机提供物体、容器和机械臂的整体空间信息；腕部相机提供夹爪附近的局部视觉信息。实际采集采用两路 640×480 像素、标称 30 帧/秒的 RGB 图像，相机输出格式设置为 MJPG。落盘视频编码与相机 USB 传输格式分开管理，保留流式视频编码以减少采集结束后的处理等待。

软件流程采用本地 Windows 计算机负责采集、开发机负责训练的分工。数据、模型配置及日志分别管理，保存版本和设备配置。后续拟在连接机械臂的本机进行推理与控制，先实测资源占用和推理延迟，再确定执行参数。

由于示教、训练和执行分布在不同计算机上，数据交接应同时包含图像字段名、任务文本、关节顺序、动作单位及归一化参数。部署时先读取同一批离线样本复现预处理结果，再接入实时设备；若字段或关节排列不一致，应停止实机执行并回查配置，防止模型输出被错误映射到机械臂。

第 2.2 节 任务设置与示教采集

基础任务定义为“拿起黄色方块并放入网状容器”。通过主从遥操作记录接近目标、夹取、抬升、搬运和释放的完整过程，同时保存图像、关节状态和动作信息。对每次采集记录机位、焦距和桌面布局，保证同组数据具有明确的视觉条件。

采集过程中逐步覆盖具有代表性的物体位置，检查失败操作、人工协助、长时间停顿和异常通信片段。不同机位数据分组保存，避免直接混合。后续根据实机失败类型补充针对性示教，而不是单纯增加重复轨迹数量。

每段示教至少应覆盖任务开始、夹爪接近、稳定抓取、移动和释放五个阶段，并让目标物、夹爪及容器持续处于至少一路相机的有效视野内。遇到遮挡、曝光突变或设备中断时记录异常原因，保证后续数据筛选可追溯。任务文本在同一批次保持一致，减少语言标注差异对单任务微调的干扰。

第 2.3 节 数据处理与模型微调

数据处理先检查视频能否完整解码、视频帧数与数据表行数是否一致，以及动作和状态是否存在无效数值。随后统一任务文本，固定双相机输入语义，并记录原始数据到合并数据的对应关系。训练集与验证集按完整示教段划分，避免将同一段轨迹拆分到两者之中。

本项目以 SmolVLA 预训练模型为起点进行任务微调，沿用视觉编码器冻结、动作专家与状态投影适配的配置。训练中保存配置、随机种子、检查点及验证记录，先通过少量步骤验证读取、前向计算、反向更新和模型保存，再执行首轮正式训练。依据离线验证和后续实机结果比较不同检查点，不仅以训练步数判断模型质量。

第 2.4 节 推理部署与评估方法

部署前拟使用已录制数据进行离线检查，核对完整模型目录、预处理与归一化配置、状态动作维度及双相机映射，并测量本机推理耗时。通过后再接入实时相机和机械臂，以“获取观察与状态—输入任务描述—预测动作—执行部分动作—重新观察”的方式进行闭环控制。

实机调试从接近示教条件的场景开始，设置关节范围和单次动作变化限制，保留人工停止方式。以规定时间内无需人工干预、将物体完整放入目标容器作为成功条件，初步安排 5 个未用于示教的起始位置，每个位置重复 4 次，共 20 次测试，记录成功率、完成时间和失败类型。

基础任务稳定后，逐项改变位置、背景或光照条件，分析场景变化的影响；条件允许时，在相同数据划分和训练预算下比较单视角与双视角配置。物品归位或分类放置等新增任务需配套采集示教并独立测试，不将单任务结果直接推广为多任务能力。

测试记录按每次试验保存起始摆放、机位、候选检查点、是否成功、执行时长和失败阶段。对于抓取失败，区分未接近目标、夹爪闭合偏移、抬升时滑落和投放不准等情况；这样既能衡量总体成功率，也能判断下一轮应补充哪类示教。模型输出的动作还需与关节限位和控制频率共同检查，避免因推理延迟或突变命令影响实验安全与可重复性。

第 3 章 已完成工作与阶段结果

第 3.1 节 平台搭建与采集流程

已完成 SO-ARM101 硬件接入、初始校准、主从遥操作和双相机配置，具备基础桌面任务的数据采集条件。完成本地 LeLab 与 LeRobot 环境配置、G 盘数据与缓存路径整理，并在开发机建立独立训练环境。已验证数据上传流程，保存设备配置、校准文件、训练脚本和数据清单。

针对前期出现的数据集名称解析错误、刷新后录制页面无法恢复等问题，对本地命名空间和录制恢复入口进行了调整。相机与串口通信仍需继续验证长时间稳定性；已完成训练不能据此证明采集端所有故障均已消除。

第 3.2 节 数据规模与质量检查

截至本轮整理，共采集 14 组数据集、92 段示教。9 月 16 日与 9 月 18 日之间调整过相机位置和焦距，因此首轮只采用 9 月 18 日的 67 段数据，共 35,651 帧。两批数据构成及本轮使用范围见表 3-1。

表 3-1 示教数据构成与首轮使用范围

采集批次	数据集数量	示教段数	本轮使用情况
2026 年 9 月 16 日	4	25	排除，机位不同
2026 年 9 月 18 日	10	67	用于首轮训练与验证
合计	14	92	按采集条件分组管理

选用数据的 20 个相机视频均完成逐帧解码，帧数与数据表一致，动作和状态未检出 NaN 或 Inf。对 67 段结束画面的抽查可见黄色方块位于容器内，但这不等于整段动作质量、图像与动作同步精度及真实采样频率均已完成验收。

合并副本采用统一语言描述，固定外部视角与腕部视角的输入映射。按完整示教段划分为 56 段训练数据和 11 段验证数据，分别为 30,305 帧与 5,346 帧。验证数据取该任务最后 11 段，与训练场景仍较接近，因此验证结果不能代表跨场景泛化能力。

第 3.3 节 模型训练与验证结果

在 A100 开发机上完成 200 步流程测试，随后从测试检查点继续训练到总计 10,000 步。正式阶段额外执行 9,800 步，含验证与保存用时约 71 分 22 秒。为共享开发机资源，采用 batch size 为 4、两个数据加载进程和低优先级执行，并限制线程和显存分配，每步保留短暂停顿。

200 步阶段完成模型更新、验证和保存。正式训练每 1,000 步保存检查点并进行最多 128 个验证样本的离线评估，最后记录的训练损失约为 0.127、验证损失约为 0.0915。部分检查点结果见表 3-2；完整日志和配置已经归档。

表 3-2 首轮训练部分检查点的验证结果

训练步数	验证损失	记录说明
3,000	0.1075	阶段检查点
5,000	0.1037	阶段检查点
6,000	0.0763	本轮所记录最低验证值
8,000	0.0944	阶段检查点
10,000	0.0915	首轮最终检查点

结果说明训练和离线验证流程已运行完成，但验证损失不能转换为机械臂抓取成功率。第 6,000 步检查点的验证值低于最终值，后续应以一致评估条件比较候选模型。由于验证样本有限且损失计算存在随机性，不将单次最低值认定为部署最优结果。

检查点比较时，应固定验证数据和推理预处理，记录每次评估的样本数及随机设置。第 6,000 步与第 10,000 步的离线损失差异提示后续需要实际对照，但在未完成重复实机测试前，无法判断较低损失是否意味着更高的抓取成功率。后续将优先保留这两个检查点作为候选，使用相同的初始摆放分别测试，避免只依据单次指标作选择。

目前未执行本轮模型的本地推理与实机自主抓取测试，也未获得真实任务成功率、控制频率或场景泛化结果。已完成的主要成果是硬件与采集平台、经初步审核的数据、可运行训练流程、模型检查点及可追溯项目文档。

第 4 章 待解决问题与进度安排

第 4.1 节 待解决的关键问题

首先需要完成本机模型加载与推理测试，核对完整预处理文件、相机语义、状态动作顺序和归一化配置。其次需要继续排查两路相机并发采集以及串口读取稳定性，避免通信异常使闭环控制中断。USB 设备索引可能随插拔变化，应通过实际画面核对外部与腕部视角，不能仅依据数字编号判断。

现有数据集中于黄色方块和单一放置任务，尚不能证明对不同物体、指令或环境具有泛化能力。后续应建立失败案例记录，区分识别偏差、抓取偏移、搬运脱落和放置失败，结合原因补录示教；对场景扩展设置独立评估，不以训练损失下降替代实际任务验证。

第 4.2 节 后续进度计划

以前期平台搭建、数据采集和首轮训练为基础，后续拟按八周推进，并结合竞赛节点调整安排。

第 1—2 周：完成部署准备。核对模型检查点和预处理配置，在本机开展不驱动机械臂的离线加载和测速，检查动作输出与资源占用，同步核查相机和串口稳定性。

第 3—4 周：开展基础任务实机验证。在固定机位与桌面环境下测试方块抓取和放置，执行不同起始位置的重复试验，统计成功率、完成时间和失败类型。

第 5—6 周：进行数据与模型改进。根据失败案例补录示教，比较不同训练检查点；条件允许时开展单视角与双视角对照，分析视觉配置与场景变化的影响。

第 7 周：开展桌面服务场景探索。选择物品归位或分类放置任务，补充示教并开展独立测试，评估基础操作能力向具体服务任务扩展的可行性。

第 8 周：完成成果整理。汇总实验数据和失败案例，形成项目报告、系统说明、演示视频及答辩材料，明确已实现功能、实验结论和改进方向。

第 4.3 节 预期成果与应用边界

预期形成一套低成本 VLA 机械臂验证平台、一套可复现的示教数据管理和模型训练部署流程，以及包含真实测试记录的桌面抓取评估报告。在基础任务稳定后，形成物品归位或分类放置的场景演示，为桌面服务机器人研究积累经验。

项目定位为限定桌面环境中的实验验证，不将其描述为已实现通用服务机器人。可推广的成果主要是实验流程、数据组织方法、系统适配经验与评估规范；实际可完成的任务范围应以重复实机测试为依据。

成果整理时拟将原始采集记录、筛选规则、训练配置、模型检查点编号和实机试验表建立对应关系。报告中分别列出已测得的结果与尚未开展的验证，并附典型成功和失败案例，使后续人员能够复现数据处理、模型训练和任务评估过程。

第 5 章 总结

本项目围绕小型机械臂上的 VLA 适配，已完成主从遥操作和双视角采集平台搭建，形成 92 段原始示教，并选择同一机位条件下的 67 段数据完成首轮 SmolVLA 微调。训练、验证、检查点保存及项目归档流程已运行完成，为后续部署提供了基础。

下一阶段将以模型输入输出一致性、通信稳定性和实机任务表现为重点，先完成本机离线检查，再开展受控的抓取与放置评估。通过重复试验、失败分析和针对性补录，逐步验证系统在桌面服务场景中的应用可行性，并客观界定当前能力与局限。

参考文献

[1] BROHAN A, BROWN N, CARBAJAL J, et al. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control[EB/OL]. (2023-07-28)[2026-09-19]. https://arxiv.org/abs/2307.15818.

[2] KIM M J, PERTSCH K, KARAMCHETI S, et al. OpenVLA: An Open-Source Vision-Language-Action Model[EB/OL]. (2024-06-13)[2026-09-19]. https://arxiv.org/abs/2406.09246.

[3] SHUKOR M, AUBAKIROVA D, CAPUANO F, et al. SmolVLA: A Vision-Language-Action Model for Affordable and Efficient Robotics[EB/OL]. (2025-06-02)[2026-09-19]. https://arxiv.org/abs/2506.01844.

[4] CHEN X, CHEN Y, FU Y, et al. InternVLA-M1: A Spatially Guided Vision-Language-Action Framework for Generalist Robot Policy[EB/OL]. (2025-10-15)[2026-09-19]. https://arxiv.org/abs/2510.13778.

[5] HUGGING FACE. LeRobot Documentation: SmolVLA[EB/OL]. [2026-09-19]. https://huggingface.co/docs/lerobot/smolvla.

[6] THE ROBOT STUDIO. SO-ARM100 / SO-ARM101 Open-Source Robotic Arm[EB/OL]. [2026-09-19]. https://github.com/TheRobotStudio/SO-ARM100.

[7] ONEROBOTAI. LeLab[EB/OL]. [2026-09-19]. https://github.com/OneRobotAI/lelab.