北京化工大学

第二十一届“萌芽杯”参赛作品—B 类

作品名称：基于 VLA 的小型机械臂验证及智能服务场景应用研究

指导教师： 李好义

负 责 人： 崔道涵

联系方式： 19560829506

2026 年 9 月 19 日

团队成员及指导老师介绍

指导老师介绍：

姓　　名	李好义	所属学院	机电工程学院
职　　称	副教授	研究方向	超细纤维先进制造工艺及装备

团队成员介绍：

姓　　名	崔道涵	所属学院	机电工程学院
专　　业	机器人工程	班　　级	机工 2502

姓　　名	李择成	所属学院	机电工程学院
专　　业	过程装备与控制工程	班　　级	装备

姓　　名		所属学院	
专　　业		班　　级	

姓　　名		所属学院	
专　　业		班　　级	

姓　　名		所属学院	
专　　业		班　　级	

目　录

第 1 章 项目概述与研究背景 4
第 1.1 节 项目简介 4
第 1.2 节 项目背景与研究意义 4
第 1.3 节 国内外研究现状 5
第 2 章 系统设计与实施方法 6
第 2.1 节 平台组成与软件架构 6
第 2.2 节 任务设置与示教采集 7
第 2.3 节 数据处理与模型微调 7
第 2.4 节 推理部署与评估方法 8
第 3 章 已完成工作与阶段结果 9
第 3.1 节 平台搭建与采集流程 9
第 3.2 节 模型训练与验证结果 9
第 4 章 待解决问题与进度安排 10
第 4.1 节 待解决的关键问题 10
第 4.2 节 后续进度计划 10
第 4.3 节 预期成果与应用边界 11
第 5 章 总结 12
参考文献 12

第 1 章 项目概述与研究背景

第 1.1 节 项目简介

本项目使用 SO-ARM101 主从机械臂和两路 RGB 摄像头，研究 VLA 模型在桌面抓取任务中的应用。外部相机拍摄机械臂和工作区，腕部相机拍摄夹爪附近的物体；LeRobot 负责数据处理与训练，SmolVLA 作为待适配的预训练模型。实验从遥操作示教开始，经过数据整理和模型微调，再进入推理与实机测试。

第一阶段选择“拿起黄色方块并放入网状容器”作为验证任务，观察模型能否完成识别、接近、抓取和放置。待这一任务得到重复测试后，再尝试物品归位和分类放置。目前机械臂搭建、遥操作、双视角采集和首轮微调已完成；本轮模型尚未接入机械臂进行自主抓取测试。

第 1.2 节 项目背景与研究意义

传统机械臂适合按固定程序重复动作。物体位置或任务要求变化后，通常需要重新设定识别条件和运动轨迹。桌面整理一类任务则经常遇到摆放位置不固定、目标物不同的问题，需要机械臂结合现场图像和任务要求调整动作。

视觉—语言—动作（Vision-Language-Action，VLA）模型把图像、文字指令和动作联系起来，为机械臂根据观察结果执行任务提供了方法。本项目更关心这一方法落到具体设备后是否有效：采集的数据能否准确记录操作，模型输出能否正确对应关节，以及同一任务能否在不同起始位置重复完成。

本项目计划建立一套可供重复实验的小型机械臂平台，记录相机布置、示教数据和模型配置，并用实机测试检验抓取效果。研究内容是开源模型在当前机械臂和桌面环境中的适配、训练及评估，创新工作主要体现在系统搭建和实验验证。

选择桌面方块抓取作为起点，主要是因为任务边界清楚：目标物和容器可以固定在工作区内，动作是否完成也容易判断。接近、闭合夹爪、抬升和投放几个环节都能在视频中观察，便于把一次失败对应到具体步骤。等这些步骤能连续完成后，再换成更接近服务场景的物品，实验难度也更容易控制。

在教学和学生科研中，这类平台还可以把模型训练与机械结构、传感器配置和控制过程联系起来。例如，夹爪接近方向不合适，可能与示教路径有关；物体在图像中变小，可能来自机位或焦距变化。把这些条件记录下来，能够帮助分析问题究竟出在数据、模型还是设备上。

第 1.3 节 国内外研究现状

RT-2 研究了如何把视觉语言模型学到的知识用于机器人动作预测[1]。OpenVLA 公开了模型和训练代码，使研究者能够在已有模型上继续适配新的机械臂任务[2]。这些工作说明，视觉和语言预训练可以为机器人操作提供有用的初始能力。

SmolVLA 采用较小的模型规模，并研究异步推理，以降低训练和执行时的资源需求[3]。国内的 InternVLA-M1 则把空间理解引入视觉语言动作模型，研究目标位置与机器人动作之间的联系[4]。不同研究使用的设备、数据和评价方法并不相同，其论文结果不能直接作为本项目的预期成功率。

模型换到 SO-ARM101 后，需要重新核对相机画面、关节顺序、动作范围和推理速度。即使离线损失下降，也要通过实机试验判断夹爪是否真正抓住物体，并观察通信或视角变化是否影响执行。本项目据此选择先完成单一桌面任务，再逐步增加测试条件。

考虑到现有设备和开发机条件，首轮训练采用 LeRobot 支持的 SmolVLA。这样可以沿用已建立的数据格式与训练工具，把工作重点放在双相机输入、动作映射和实机效果上。

实验将围绕三个具体问题展开：两路相机能否稳定覆盖抓取过程；现有示教能否让模型适应这台机械臂；离线验证结果与实机表现是否一致。先固定机位和桌面布置，再单独改变物体起始位置或相机条件，以便分析失败原因。

第 2 章 系统设计与实施方法

第 2.1 节 平台组成与软件架构

系统包括一套 SO-ARM101 主从机械臂、两路 RGB 摄像头、本地采集电脑和开发机。LeRobot 用于数据处理、训练与部署[5]，机械臂结构参考 SO-ARM101 开源方案[6]，LeLab 辅助设备配置和采集[7]。模型使用的状态和动作各有六个数值，对应五个关节和一个夹爪通道。

采集时由人操作主臂，从臂同步执行。外部相机记录物体、容器和机械臂的相对位置，腕部相机记录夹爪附近的细节。两路图像设为 640×480 像素、标称 30 帧/秒，摄像头 USB 输出采用 MJPG；采集软件另行负责视频编码和保存。

本地 Windows 电脑连接机械臂和摄像头，负责采集；开发机负责模型训练。数据、配置和日志分别保存。实机部署前，先在连接机械臂的电脑上测量模型加载时间、显存占用和单次推理耗时，再决定控制频率。

采集与训练分在两台电脑进行，因此移交数据时必须同时核对图像字段名、任务文本、关节顺序、动作单位和归一化参数。模型部署前先用已录制样本检查预处理和输出，再连接实时设备；若关节排列与训练时不同，应先修正配置。

两路相机承担的观察任务不同。固定相机适合检查方块和容器在桌面上的位置，腕部相机更便于观察夹爪是否对准方块。布置时需要兼顾两者：固定相机应覆盖整个操作区域，腕部相机应在夹爪接近时仍能看到目标，导线则应避开关节和夹爪的活动范围。相机支架或镜头一旦调整，后续试验需注明变化。

本地推理方案将先测试摄像头取帧、模型计算和动作发送各自的耗时，再检查整个循环。若模型单次输出一段动作，拟先执行其中较短的一部分便重新观察，以便及时修正方块偏移或抓取失败。具体执行长度要通过测速和实机观察确定，不能只按摄像头的标称帧率设定。

第 2.2 节 任务设置与示教采集

示教任务是“拿起黄色方块并放入网状容器”。通过主从遥操作记录机械臂接近方块、闭合夹爪、抬升、搬运和释放的过程，同时保存图像、关节状态和动作。每批采集记录相机位置、焦距及桌面布置。

采集时适当改变方块起始位置，并标记失败抓取、人工协助、长时间停顿或通信中断的片段。9 月 16 日和 9 月 18 日的相机位置及焦距不同，因此分别保存。后续补录哪些示教，将依据实机失败情况决定。

一段可用的示教应从任务开始记录到释放结束，目标物、夹爪和容器至少在一路相机中可见。若出现明显遮挡、曝光变化或设备掉线，应记录发生时间，便于回看与筛选。同批数据使用相同任务描述。

示教时还需保持任务起止条件一致。开始前将机械臂放回约定姿态，确认方块没有被夹住；完成投放后短暂停留，让视频能清楚记录最终状态。随后停止这一段采集，再复位方块和机械臂，避免把人工整理桌面的过程录入任务动作。

为了让后续试验有可比较的条件，拟在桌面标出若干起始区域，分别用于示教和测试。测试区域可与示教区域相邻，但不完全重合。物体材质、容器和光照先保持一致，待位置变化的影响明确后，再单独引入新物体或背景。

第 2.3 节 数据处理与模型微调

整理数据时，先检查视频是否能解码、帧数是否与数据表一致，以及动作和状态是否含无效数值。之后统一任务描述和两路相机的字段名，并保留原始数据与合并数据的对应关系。训练集与验证集按完整示教段划分。

模型以 SmolVLA 预训练权重为起点，训练时冻结视觉编码器，更新动作专家及状态投影部分。先运行少量步骤，确认数据读取、参数更新、验证和保存都正常，再开展正式训练。训练配置、随机种子、检查点和日志一并保存，便于复现。

训练和实机执行使用同样的图像字段及关节排列十分关键。训练样本中的外部相机如果在部署时被换成腕部相机，模型看到的画面含义就会改变；动作归一化参数使用错误，也会改变输出数值对应的关节运动。因此，每次训练应把预处理配置与权重一起保存，部署时按同一版本加载。

对于同一任务，模型可能学会沿着常见示教路径运动，却没有充分适应新的摆放位置。后续补录将优先覆盖实机中反复失败的位置和接近方向，同时保留原有示教，观察新数据能否改善失败情况。新增轨迹是否有效，最终仍需通过相同条件下的重复测试判断。

第 2.4 节 推理部署与评估方法

部署前先读取已录制数据，核对模型目录、预处理文件、归一化配置、六维状态与动作顺序，以及两路相机对应的字段。确认输出合理并测得推理耗时后，再接入实时相机和机械臂，按“观察—预测—执行—再次观察”的顺序测试。

实机测试先保持相机位置和桌面布置与示教时一致，限制单次动作幅度和关节范围，并保留人工停止方式。计划选择 5 个未用于示教的起始位置，每个位置重复 4 次，共 20 次。方块在规定时间内由机械臂独立放入容器，才记为成功；同时记录用时和失败环节。

固定条件下的测试完成后，再分别改变方块位置、背景或光照。若数据量允许，可在相同划分和训练步数下比较单相机与双相机输入。物品归位或分类放置属于新增任务，需要另外采集示教并单独评价。

每次试验记录起始位置、相机配置、所用检查点、执行时间和结果。抓取失败时，注明是未接近目标、夹爪闭合偏移、抬升滑落还是投放不准。除成功率外，还需检查输出动作是否超过关节限位，以及推理延迟是否让控制过程明显停顿。

评价时将分别统计完整任务成功和各阶段失败次数。方块被夹起后掉落、移到容器上方但未落入，以及需要人工帮助才能完成，都记为该次任务失败。对于成功试验，再计算完成时间；对于中断试验，另记中断原因，避免将设备掉线与策略判断错误混在一起。

现阶段只训练一种任务描述，因此首轮试验主要检验视觉条件下的抓取执行。模型是否能理解不同指令，需要另设实验。例如，在相同桌面上给出不同目标物或放置位置的指令，观察动作是否随指令改变。在完成这类对照之前，报告只说明本次任务的执行结果。

第 3 章 已完成工作与阶段结果

第 3.1 节 平台搭建与采集流程

目前已接入 SO-ARM101，完成初始校准、主从遥操作和两路相机配置；本地 LeLab、LeRobot 及 G 盘数据路径可以用于采集，开发机训练环境也已建立。设备配置、校准文件、数据清单和训练脚本已有归档。

采集初期曾遇到数据集名称解析错误、刷新后录制页面无法恢复等问题，已调整本地命名和录制恢复入口。两路相机同时工作及串口读取的长时间稳定性仍需继续观察。

前期排查也表明，网页显示的录制条数不足并不能单独说明相机损坏。一次采集涉及图像读取、串口通信、视频编码和文件写入，任一环节退出都会影响结果。后续复测将保留运行日志，对照出错时间检查相机和机械臂状态；涉及机位或接线的调整，也会在试验记录中注明。

第 3.2 节 模型训练与验证结果

训练先在 A100 开发机上运行 200 步，确认流程正常，再从该检查点继续至总计 10,000 步。后续 9,800 步连同验证和保存用时约 71 分 22 秒。为减少对开发机上其他任务的影响，batch size 设为 4，使用两个数据加载进程，并以较低优先级运行。

正式训练每 1,000 步保存检查点，并在最多 128 个验证样本上计算离线损失。训练结束时，训练损失约 0.127，验证损失约 0.0915。表 3-1 列出部分检查点，完整配置和日志已归档。

表 3-1 首轮训练部分检查点的验证结果

训练步数	验证损失	记录说明
3,000	0.1075	阶段检查点
5,000	0.1037	阶段检查点
6,000	0.0763	本轮所记录最低验证值
8,000	0.0944	阶段检查点
10,000	0.0915	首轮最终检查点

第 6,000 步检查点的验证损失为 0.0763，低于第 10,000 步的 0.0915。但验证样本较少，且离线损失反映的是模型预测与数据的差异，不能直接当作抓取成功率。两个检查点都保留，待在相同起始位置上进行实机比较。

表中不同检查点的验证值并非持续下降，这提示继续增加训练步数未必能改善当前验证结果。由于本轮评估样本有限，也不能据此直接认定模型已经过拟合。后续先固定验证设置复测候选检查点，再比较实机表现，以确定是否需要增加训练、补录数据或调整输入配置。

本轮模型尚未完成本机推理与实机自主抓取测试，因此暂时没有任务成功率、控制频率和跨场景测试结果。现阶段已有的是可用的采集平台、初步核查的数据、训练日志和模型检查点。

第 4 章 待解决问题与进度安排

第 4.1 节 待解决的关键问题

下一步先在本机加载模型，核对预处理、相机字段、状态与动作顺序以及归一化参数。随后检查两路相机同时采集和串口读取是否稳定。USB 设备编号可能在重新插拔后变化，测试前应查看实际画面，确认外部视角与腕部视角没有接反。

现有数据只覆盖黄色方块放入容器这一任务，无法说明模型对其他物体或指令也有效。实机失败后，应记录具体是定位、夹取、搬运还是放置环节出了问题，再按问题补录数据。新增场景需要单独测试。

相机条件改变后的适应能力也是后续要检查的问题。第一次对照拟保持机械臂校准和物体不变，只对固定相机做小范围位置调整，记录图像中目标的位置与大小变化，并与原机位结果比较。若性能明显下降，再考虑补录对应机位的示教。这样可以把视觉变化的影响与机械臂校准问题区分开。

第 4.2 节 后续进度计划

后续工作暂按八周安排，具体时间结合竞赛节点调整。

第 1—2 周：完成部署准备。核对模型检查点和预处理配置，在本机开展不驱动机械臂的离线加载和测速，检查动作输出与资源占用，同步核查相机和串口稳定性。

第 3—4 周：开展基础任务实机验证。在固定机位与桌面环境下测试方块抓取和放置，执行不同起始位置的重复试验，统计成功率、完成时间和失败类型。

第 5—6 周：进行数据与模型改进。根据失败案例补录示教，比较不同训练检查点；条件允许时开展单视角与双视角对照，分析视觉配置与场景变化的影响。

第 7 周：开展桌面服务场景探索。选择物品归位或分类放置任务，补充示教并开展独立测试，评估基础操作能力向具体服务任务扩展的可行性。

第 8 周：完成成果整理。汇总实验数据和失败案例，形成项目报告、系统说明、演示视频及答辩材料，明确已实现功能、实验结论和改进方向。

第 4.3 节 预期成果与应用边界

预期提交 SO-ARM101 桌面实验平台、示教数据整理与模型训练记录，以及包含实机成功率和失败案例的抓取测试报告。基础任务经重复测试后，再制作物品归位或分类放置的演示。

本项目目前只针对限定桌面环境开展实验。相机、物体或任务变化后的表现，需要逐项测试；已有训练结果不能说明机械臂具备通用服务能力。

最终报告将列出原始采集记录、筛选规则、训练配置、检查点编号和每次实机试验结果，并附典型成功与失败案例。这样可以查清一次结果对应的设备布置、数据和模型版本。

桌面服务场景拟从边界明确的小任务开始。例如，物品归位可以先设定单一物体和固定收纳区；分类放置则需要增加可区分的物体与目标区域，并配套采集示教。每增加一类任务，都要重新检查夹爪能否稳定夹持、相机是否覆盖操作区，以及模型是否确实根据目标完成放置。

第 5 章 总结

目前已搭建 SO-ARM101 主从遥操作与双视角采集平台，录制 92 段示教；其中 67 段在同一机位条件下完成首轮 SmolVLA 微调。训练及离线验证均已运行，模型检查点和配置文件已保存。

接下来先在本机检查模型输入输出和推理速度，再进行受控的抓取放置试验。根据实机失败记录补录示教，比较不同检查点在相同条件下的表现，最后再判断这一方法能否用于物品归位等桌面服务任务。

参考文献

[1] BROHAN A, BROWN N, CARBAJAL J, et al. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control[EB/OL]. (2023-07-28)[2026-09-19]. https://arxiv.org/abs/2307.15818.

[2] KIM M J, PERTSCH K, KARAMCHETI S, et al. OpenVLA: An Open-Source Vision-Language-Action Model[EB/OL]. (2024-06-13)[2026-09-19]. https://arxiv.org/abs/2406.09246.

[3] SHUKOR M, AUBAKIROVA D, CAPUANO F, et al. SmolVLA: A Vision-Language-Action Model for Affordable and Efficient Robotics[EB/OL]. (2025-06-02)[2026-09-19]. https://arxiv.org/abs/2506.01844.

[4] CHEN X, CHEN Y, FU Y, et al. InternVLA-M1: A Spatially Guided Vision-Language-Action Framework for Generalist Robot Policy[EB/OL]. (2025-10-15)[2026-09-19]. https://arxiv.org/abs/2510.13778.

[5] HUGGING FACE. LeRobot Documentation: SmolVLA[EB/OL]. [2026-09-19]. https://huggingface.co/docs/lerobot/smolvla.

[6] THE ROBOT STUDIO. SO-ARM100 / SO-ARM101 Open-Source Robotic Arm[EB/OL]. [2026-09-19]. https://github.com/TheRobotStudio/SO-ARM100.

[7] ONEROBOTAI. LeLab[EB/OL]. [2026-09-19]. https://github.com/OneRobotAI/lelab.